Balanceamento de Carga e CDN

Conceitos e Práticas de Redes Cloud — Aula 8

Prof. Alexandre da Costa Tavares Junior



Agenda

- Recapitulação: Arquiteturas de Referência
- O que é Balanceamento de Carga?
- Tipos de Load Balancer (ALB, NLB, GWLB)
- Roteamento baseado em conteúdo
- Algoritmos de distribuição
- Health Checks
- O que é CDN?
- Cache Hit vs. Cache Miss
- CDN para conteúdo dinâmico
- Arquitetura Integrada: LB + CDN
- Resumo e Próxima Aula



Recapitulação

> **Aula anterior — Arquiteturas de Referência:**
> Well-Architected Framework (5 pilares)
> Three-Tier, Microsserviços, Serverless, Event-Driven
> Alta Disponibilidade Multi-AZ e Auto Scaling

Conexão com hoje: Load Balancer e CDN são COMPONENTES FUNDAMENTAIS dessas arquiteturas — agora vamos entender como funcionam em detalhe.



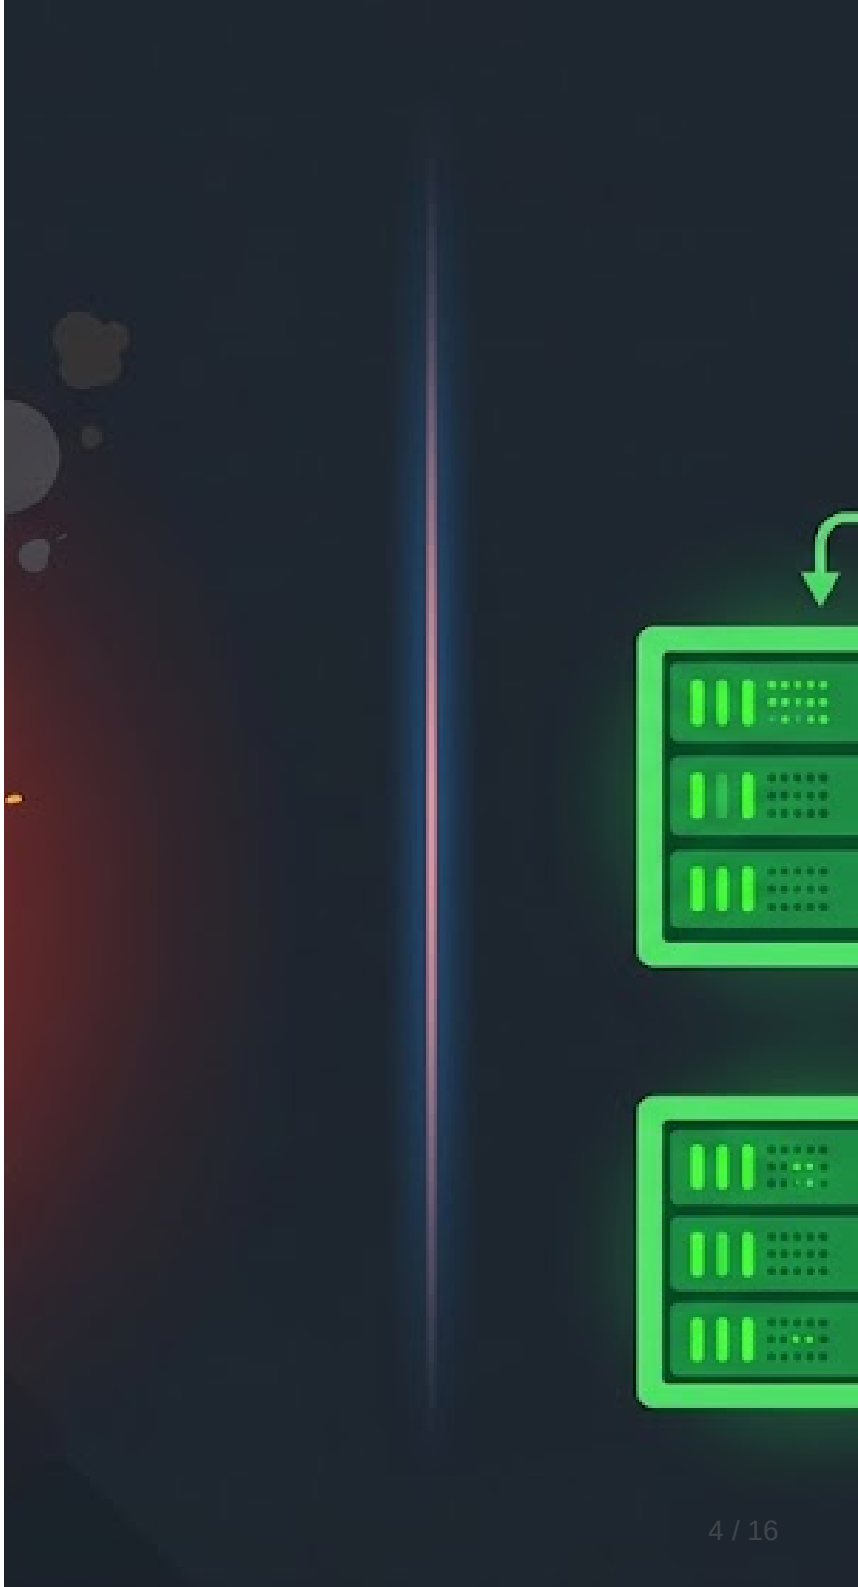
O Problema: Servidor Único

❌ Sem Load Balancer

- Ponto único de falha
- Capacidade limitada
- Downtime em manutenção
- Degradação com carga

✅ Com Load Balancer

- Redundância
- Escalabilidade horizontal
- Zero downtime
- Distribuição inteligente



Tipos de Load Balancer

Tipo	Camada	Protocolo	Uso Principal
ALB	7 (Aplicação)	HTTP/HTTPS	Apps web, APIs
NLB	4 (Transporte)	TCP/UDP/TLS	Alta performance
GWLB	3 (Rede)	IP/GENEVE	Appliances segurança

Equivalentes:

- AWS: ALB / NLB / GWLB
- Azure: Application Gateway / Load Balancer
- GCP: HTTP(S) LB / TCP/UDP LB



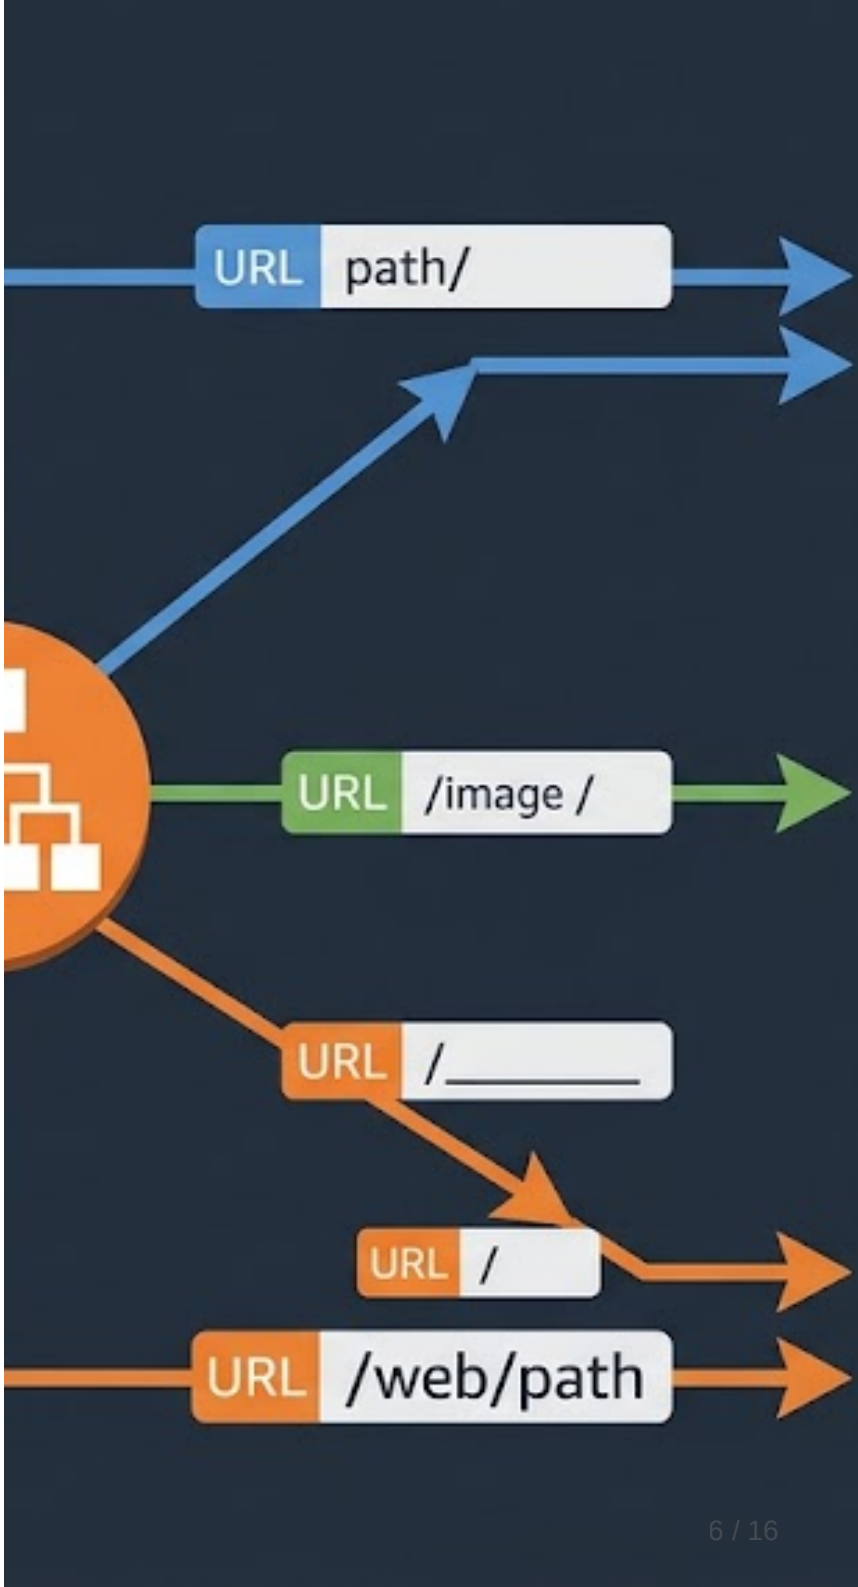
ALB: Roteamento por Conteúdo

```
/api/*       → Target Group: API Servers
/images/*    → Target Group: Image Servers
/*           → Target Group: Web Servers

Host: admin.site.com → Target Group: Admin
```

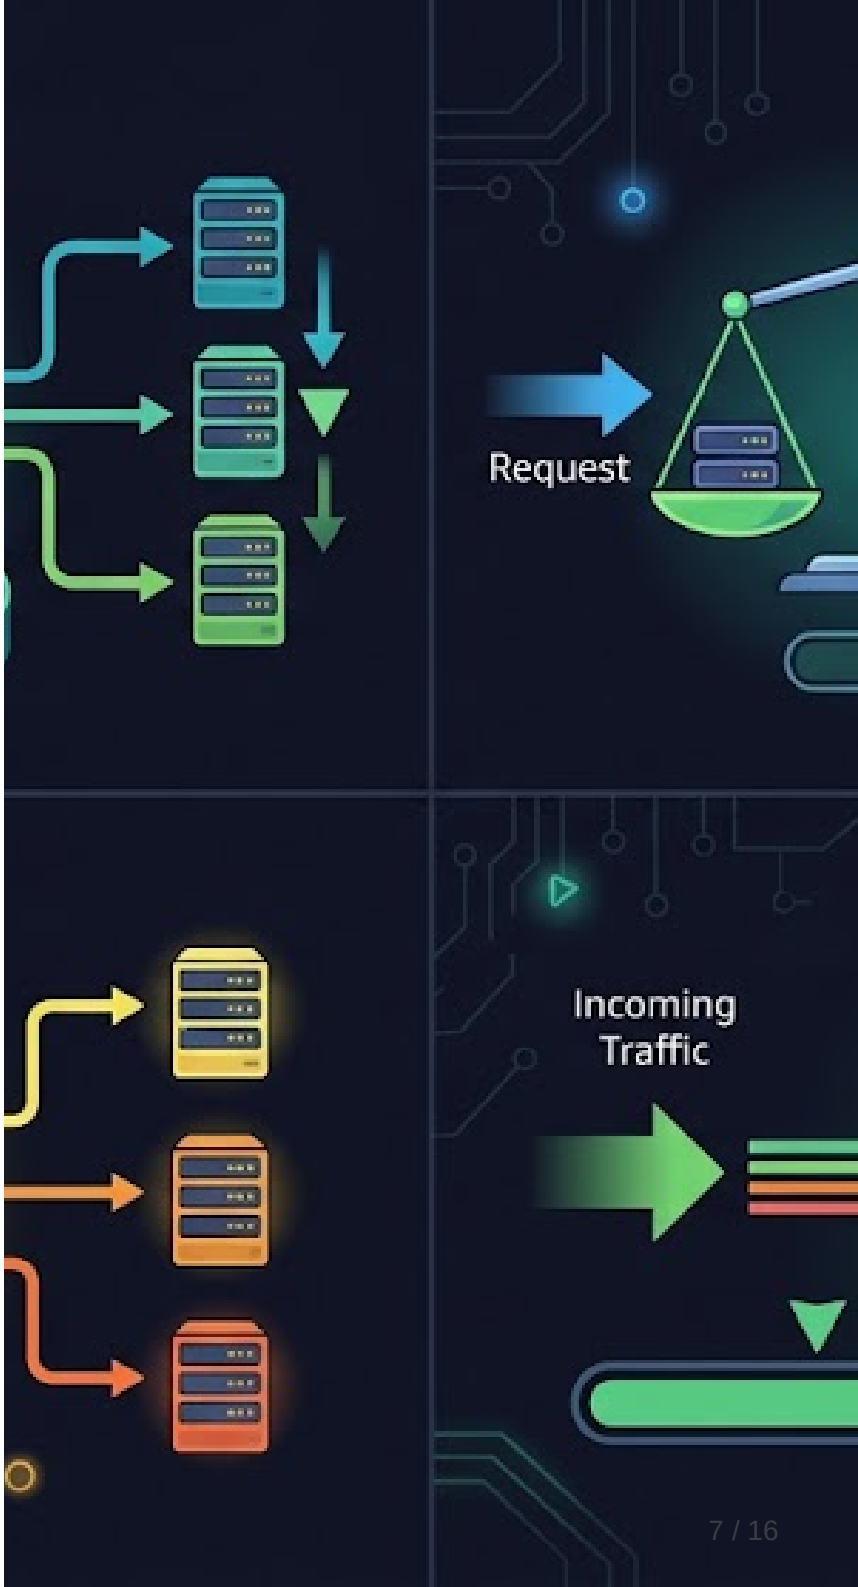
Regras baseadas em:

- Path da URL
- Host header (domínio)
- HTTP headers customizados
- Query strings
- IP de origem



Algoritmos de Distribuição

Algoritmo	Como funciona	Ideal para
Round Robin	Sequencial	Servidores homogêneos
Least Outstanding	Menos req. pendentes	Tempo variável
Flow Hash	Hash da conexão	Sessões persistentes
Weighted	Proporção configurável	Canary deploy



Health Checks

Fluxo:

1. LB envia verificação periódica (HTTP GET /health)
2. Target responde 200 = saudável ✅
3. Falhas consecutivas → marcado *unhealthy* ❌
4. Removido do pool → tráfego redistribuído
5. Recuperou → volta ao pool automaticamente

> **Parâmetros:** Interval: 30s | Timeout: 5s | Unhealthy: 2 falhas | Healthy: 3 sucessos



O que é CDN?

Content Delivery Network: Rede global de edge locations que armazenam conteúdo próximo aos usuários.

❌ Sem CDN

SP → Virginia (EUA)

~150ms de latência

✅ Com CDN

SP → Edge SP

~5ms de latência

CloudFront | Azure CDN | Cloud CDN | Cloudflare



Cache Hit vs. Cache Miss

⚡ Cache Hit (rápido)

```
Usuário → Edge (tem cache) → Resposta direta
Latência: ~5-20ms
```

🔄 Cache Miss (primeira vez)

```
Usuário → Edge (não tem) → Origem → Armazena → Responde
Latência: ~100-200ms (apenas na 1ª vez)
```

> **Métrica-chave:** Hit Ratio > 90% = CDN bem configurada



Políticas de Cache (TTL)

Conteúdo	TTL	Estratégia
JS/CSS versionados	1 ano	Hash no filename
Imagens	1-7 dias	Invalidation se mudar
HTML de páginas	5 min - 1h	Frescor vs. performance
APIs dinâmicas	0-60s	Cache curto ou nenhum

Headers:

- `Cache-Control: max-age=86400` (24h)
- `Cache-Control: no-store` (nunca)
- `ETag` (revalidação condicional)



CDN Moderna: Além do Cache

Edge Computing:

- Lambda@Edge / CloudFront Functions
- Execução de lógica na borda da rede
- A/B testing, personalização, autenticação

Casos de uso avançados:

- 🎬 Streaming de vídeo (HLS/DASH)
- 🛡️ Proteção DDoS distribuída
- 🌐 Aceleração de APIs dinâmicas
- 📦 Download de software (game patches)
- 🔐 WAF na edge



Arquitetura Integrada: CDN + LB

```
Usuário → CDN (Edge)
              |
    Hit? → Resposta direta ⚡ (~80-95% tráfego)
              |
    Miss? → Load Balancer → ASG → BD
```

Resultado:

- CDN absorve 80-95% do tráfego estático
- LB processa apenas tráfego dinâmico
- Servidores com carga reduzida
- Custo otimizado (egress CDN mais barato)



Resumo

Pontos-chave desta aula:

- Load Balancer: distribui tráfego, garante HA e escalabilidade
- ALB (L7) para HTTP; NLB (L4) para performance extrema
- Health checks removem targets com falha automaticamente
- CDN reduz latência via edge locations próximas
- Cache hit = instantâneo; cache miss = busca na origem
- CDN + LB = combinação essencial para produção

Próxima aula: Segurança de Rede em Nuvem



Referências

- AMAZON WEB SERVICES. *Elastic Load Balancing User Guide*. AWS Documentation, 2024.
- AMAZON WEB SERVICES. *Amazon CloudFront Developer Guide*. AWS Documentation, 2024.
- GRIGORIK, I. *High Performance Browser Networking*. O'Reilly Media, 2013.
- NEWMAN, S. *Building Microservices*. 2. ed. O'Reilly Media, 2021.
- VERAS, M. *Cloud Computing*. 2. ed. Brasport, 2019.



Atividade

📝 Tarefa Formativa (TF)

Responda às 8 questões objetivas sobre Balanceamento de Carga e CDN.

💭 Para reflexão

Você é arquiteto de uma plataforma de streaming com usuários no Brasil, Europa e Ásia. Como combinaria LB e CDN para garantir baixa latência global? Quais conteúdos cachear e com qual TTL?

